

Segundo Taller

jueves, 24 de abril de 2025 2:00 p. m.

1. Determine el valor de verdad de las siguientes afirmaciones.

(a) Una suma de cuadrados extra mide la reducción marginal en el SSE cuando una o varias variables predictoras son agregadas al modelo de regresión, dado que las otras predictoras ya fueron agregadas o están en el modelo.

(b) El estadístico T correspondiente al procedimiento de prueba empleado para probar la significancia marginal del j -ésimo parámetro es:

$$T_{j,0} = \frac{\hat{\beta}_j - 0}{\sqrt{\sigma^2 c_{jj}}} \sim t_{n-p}$$

Falso.

Con una región de rechazo asociada de $R_c = \{|T_0| > t_{\alpha/2, n-p}\}$ y p -valor $P(|t_{n-p}| > |T_{j,0}|)$.

(c) Valores grandes de R^2 implican que la superficie ajustada de respuesta es útil, sin embargo, es menos preferido que R_{adj}^2 como medida de bondad de ajuste.

$$Y_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_k X_{ik} + \varepsilon_i; \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$$

$$T_{j,0} = \frac{\hat{\beta}_j - 0}{\sqrt{\sigma^2 c_{jj}}} = \frac{\hat{\beta}_j - 0}{\sqrt{MSE c_{jj}}} \sim t_{n-p}$$

σ^2 desviación estándar; $\hat{\sigma}^2 = MSE \rightarrow \sigma^2$

$$Y = X\beta + \varepsilon; \quad \varepsilon \sim N(0, \sigma^2 I_n); \quad \hat{\beta} \sim N(\beta, (X^T X)^{-1} \sigma^2)$$

$$C_{jj} = \text{diag}(X^T X)^{-1}$$

R^2 : proporción $0 \leq R^2 \leq 1$

$R_{adj}^2 \geq R^2$

: la proporción de variabilidad explicada por el modelo dado la relación lineal entre la variable respuesta y las demás covariadas

Principio de parsimonia : Afirmación falsa.

No

(d) Rechazar la hipótesis nula $H_0: \beta_0 = \beta_1 = \dots = \beta_k = 0$ permite determinar la significancia global de un modelo de regresión $Y_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_k X_{ik} + \varepsilon_i; \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$ a través de un procedimiento de sumas de cuadrados extra o procedimiento lineal general. Falso.

(e) El estadístico F correspondiente al procedimiento de prueba empleado para probar la significancia global del modelo de regresión lineal múltiple es:

$$F_0 = \frac{SSR/k}{SSE/(n-k)} \sim f_{k, n-k}$$

Falso

Con una región de rechazo asociada de $R_c = \{F_{calc} > f_{\alpha, k, n-k}\}$ y p -valor $P(f_{k, n-k} > F_{calc})$.

(f) Se puede demostrar que $F_{j,0} = T_{j,0}^2$ únicamente si se pretende determinar la significancia marginal de un coeficiente de regresión, lo que implica que $P(f_{1, n-p} > F_{j,0}) \equiv P(|t_{n-p}| > |T_{j,0}|)$.

(g) Los grados de libertad del cuadrado medio debido a la hipótesis son iguales al rango de la matriz L, asociada la prueba lineal general ($H_0: L\beta = 0$ vs $H_1: L\beta \neq 0$). Verdadero.

Probar significancia individual: $\begin{cases} H_0: \beta_j = 0 \\ H_1: \beta_j \neq 0 \end{cases} \quad j = 0, \dots, k$

$$Y_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_k X_{ik} + \varepsilon_i; \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$$

$$P(F_{1, n-p} > F_{j,0}) = P(|t_{n-p}| > |T_{j,0}|)$$

$L\beta = 0$ Prueba lineal general

Verdadera: P.H.: Significancia

$$Y_i = \beta_0 + \beta_1 X_{i1} + \varepsilon_i; \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2) : R^2 :$$

Y_i

$H_0: \beta_1 = 0$

$$Y_i = \beta_0 + \beta_1 X_{i1}$$

No Sig.

Falso
Verdadera

X₁

X₁

$$C_{jj} = \text{diag}(X^T X)^{-1}$$

: Significación global: Probar el ef. Covariadas

$$H_0: \beta_1 = \dots = \beta_k = 0$$

$$H_1: \text{Algun } \beta_j \neq 0, j = 1, \dots, k$$

$$F_0 = \frac{SSR/k}{MSE} = \frac{SSR/k}{SSE/(n-p)}$$

$$p = k+1$$

parámetros
Número
observ.

$$R_i: \{ F_0 > f_{\alpha, k, n-p}; \quad P(f_{\alpha, k, n-p} > F_0) \}$$

$$T_{j,0} = \frac{\hat{\beta}_j - 0}{\sqrt{\sigma^2 c_{jj}}} = \frac{\hat{\beta}_j - 0}{\sqrt{MSE c_{jj}}} \sim t_{n-p}$$

$$F_0: \frac{SSR/k}{SSE/(n-p)} \sim f_{k, n-p}$$

$$k=1: \quad T_{j,0}^2 = F_{j,0}$$

$$Y_i = \beta_0 + \beta_1 X_{i1} + \varepsilon_i$$

$$L = \begin{bmatrix} 1 & 0 & 1 & 0 & 1 \end{bmatrix} = 1=2$$

$\rightarrow LB = 0$ Prueba lineal general: $F = \frac{MSH}{MSE} = \frac{SSH/V}{MSE}$

Rango matricial: las filas no nulas linealmente independientes

$$\begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = 1 \neq 2$$

Parte práctica: Y_i : Performance; X_{i1} : Fuerza; X_{i2} : Habilidad; X_{i3} : Velocidad

. $Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \epsilon_i$; $\epsilon_i \sim N(0, \sigma^2)$: $Y = X\beta + \epsilon$; $\epsilon_i \sim N(0, \sigma^2 I_n)$

$$Peri = \hat{\beta}_0 + \hat{\beta}_1 X_{i1} + \hat{\beta}_2 X_{i2} + \hat{\beta}_3 X_{i3}$$

$$Peri = 70,80 + 0,88 X_{i1} + 1,87 X_{i2} + 3,07 X_{i3}$$

Coefficients:					
	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	70.80225	2.45665	28.82	<2e-16 ***	
X1	0.88463	0.02848	31.06	<2e-16 ***	
X2	1.87368	0.02073	90.41	<2e-16 ***	
X3	3.04502	0.02789	109.19	<2e-16 ***	

2. Determine la significancia de la regresión global a través del método de sumas de cuadrados extra. ¿Cree usted que puede realizarse esta prueba empleando otro método? De ser así, pruébelo.

$$\begin{cases} H_0: \beta_1 = \beta_2 = \beta_3 = 0 \\ H_1: \text{Algun } \beta_j \neq 0; j=1,2,3 \end{cases}$$

. Considerar un modelo completo y reducido : MF: $Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \epsilon_i$

MR: $Y_i = \beta_0 + \epsilon_i$; $\epsilon_i \sim N(0, \sigma^2)$; $s=0$ # Con. mod. red.

$$F = \frac{[SSR(MF) - SSR(MR)]/V}{MSE(MF)} \sim F_{v, n-p} = \frac{[SSE(MR) - SSE(MF)]/V}{MSE(MF)}$$

$F_{cal} > f_{\alpha/2, v, n-p}$; $P(F_{cal} > F_{cal})$

• Sumas de cuadrados extra

$$F = \frac{SSR(\beta_0, \beta_1, \beta_2, \beta_3 | \beta_0)}{MSE(\beta_0, \beta_1, \beta_2, \beta_3)} = \frac{[SSR(\beta_0, \beta_1, \beta_2, \beta_3) - SSR(\beta_0)]/V}{MSE(\beta_0, \beta_1, \beta_2, \beta_3)} = \frac{SSE(\beta_0) - SSE(\beta_0, \beta_1, \beta_2, \beta_3)/V}{MSE(\beta_0, \beta_1, \beta_2, \beta_3)}$$

V: Grados de libertad

$$V = g_1(SSR(MF)) - g_1(SSR(MR)) = g_1(SSE(MR)) - g_1(SSE(MF))$$

$$\begin{aligned} V &= K - S \\ &= (n-p) - (n-m) \\ &= -p + m \end{aligned}$$

. En resumen: $V = \# \text{ parámetros en la hipótesis nula}$

$$\begin{aligned} V &= 3 \\ n &= 500 \\ p &= 4 \end{aligned}$$

```
> anova(modelo_reducido)
Analysis of Variance Table

Response: Y
          Df  Sum Sq Mean Sq F value Pr(>F)
Residuals 499 2183751 4376.3
```

$$SSE(MR) = 2183751$$

```
> anova(modelo)
Analysis of Variance Table

Response: Y
          Df  Sum Sq Mean Sq F value Pr(>F)
X1        1    78308   78308 755.26 < 2.2e-16 ***
X2        1   817773   817773 7887.27 < 2.2e-16 ***
X3        1 1236243 1236243 11923.33 < 2.2e-16 ***
Residuals 496 51427   104
```

$$SSE(MF) = 51427$$

$$V = 499 - 496 = 3$$

```
> MSE <- SSE_completo/(n-p)
> MSE
[1] 103.6835
```

$$F = \frac{[SSE(MR) - SSE(MF)]/V}{MSE} = \frac{[2183751 - 51427]/3}{103.6835} = 103.6835$$

```
> anova_comparacion <- anova(modelo_reducido, model)
> anova_comparacion
Analysis of Variance Table

Model 1: Y ~ 1
Model 2: Y ~ X1 + X2 + X3
  Res.Df   RSS Df Sum of Sq    F Pr(>F)
1     499 2183751
```

→ Utilizando el truco

• α : A un nivel de significancia de 5% se puede rechazar una hipótesis al 0.1

Model 1: $Y \sim 1$					
Model 2: $Y \sim X_1 + X_2 + X_3$					
Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1 499 2183751					
2 496 51427 3	2132324 6855.3 < 2.2e-16 ***				

• α : A un nivel de significancia del 5% se puede establecer que el modelo es significativo: Al menos un β_j es diferente de cero / Al menos un β_j es significativo

• Esto también se puede con la prueba lineal general

$$\begin{cases} H_0: \beta_1 = \beta_2 = \beta_3 = 0 \\ H_1: \text{Algun } \beta_j \neq 0 ; j=1,2,3 \end{cases} : L\beta = 0$$

$$H_0: \beta_1 = 0 \quad \text{vs} \quad H_1: \text{Algún } \beta_j \neq 0 ; j=1,2,3$$

$$\cdot L\beta = 0: \begin{vmatrix} 1 & 0 & 0 & 0 & \beta_1 \\ 0 & 1 & 0 & 0 & \beta_2 \\ 0 & 0 & 1 & 0 & \beta_3 \end{vmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$F = \frac{SST / r}{MSE} = \frac{[2183751 - 51427] / 3}{103,6835}$$

3. Determine la significancia de los parámetros individuales β_j , junto con intervalo de confianza. Brinde una interpretación apropiada.

$$T_{0,05} = \frac{\hat{\beta}_0 - 0}{\text{Var}(\hat{\beta}_0)} = \frac{\hat{\beta}_0 - 0}{\sqrt{\text{MSE}(\hat{\beta}_0)}} \sim t_{n-p} : P(|t| \geq |T_{0,05}|) ; R_c = \{ |T_{0,05}| \} \text{ para } \alpha = 0,05$$

Coefficients:					
	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	70.88225	2.45665	28.82	<2e-16 ***	
X1	0.88463	0.02848	31.06	<2e-16 ***	
X2	1.87368	0.02073	90.41	<2e-16 ***	
X3	3.04502	0.02789	109.19	<2e-16 ***	

• A un nivel de significancia del 5%, se pueden establecer que el Intercepto es significativo en función de las demás covariables.

• A un nivel de sig. del 5%, se puede establecer que el efecto de la fuerza es significativo ($\hat{\beta}_1$) es significativamente distinto de cero.

$$\hat{\beta}_j \pm t_{n-p} \cdot \sqrt{\text{Var}(\hat{\beta}_j)} : \hat{\beta}_1 \pm t_{0,025, n-p} \cdot \sqrt{\text{Var}(\hat{\beta}_1)}$$

```
> confint(modelo)
2.5 % 97.5 %
(Intercept) 65.9755369 75.6289713
X1 0.8286681 0.9405966
X2 1.8329626 1.9144035
X3 2.9902333 3.0998132
```

• Con una confianza del 95%. Se puede establecer que el efecto promedio de la fuerza está comprendido entre 0,82 y 0,94 unidades; es decir, que por unidad de cambio en la fuerza, el rendimiento promedio varía entre 0,82 y 0,94 unidades.

en promedio cambios covariables.

De esto apende la cobertura de un intervalo

Verificar la significancia de parámetros: Si el IC contiene 0, entonces el parámetro no es signif.

$$R_1 = R_2 \dots R_n = R_1 / b_1 \dots R_n / b_n$$

4. Determine si el efecto de la primera covariable es el mismo que el efecto de la tercera covariable; al mismo tiempo, verifique si el correspondiente efecto de la primera co-

ANOVA (ejemplo).

4. Determine si el efecto de la primera covariable es el mismo que el efecto de la tercera covariable; al mismo tiempo, verifique si el correspondiente efecto de la primera covariable es el mismo que el de la segunda covariable. Plantee una prueba de hipótesis para ello y realice el procedimiento adecuado. Reporte el modelo completo y el modelo reducido.

$$\begin{array}{l} H_0: \beta_1 = \beta_3 \text{ vs } H_1: \beta_1 \neq \beta_3 \\ \beta_1 = \beta_3 \end{array}$$

$$H_0: \beta_1 = \beta_3 \text{ vs } H_1: \beta_1 \neq \beta_3$$

$$\beta = 0 \rightarrow \begin{bmatrix} 0 & 1 & 0 & -1 \\ 0 & 1 & -1 & 0 \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \quad t=2$$

$$MF: Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \epsilon_i$$

$$MR: \begin{aligned} Y_i &= \beta_0 + \beta_1 X_{i1} + \beta_1 X_{i2} + \beta_1 X_{i3} + \epsilon_i \\ Y_i &= \beta_0 + \beta_1 (X_{i1} + X_{i2} + X_{i3}) + \epsilon_i \end{aligned}$$

$$F = \frac{SSR / 2}{MSE}$$

```
> anova_LG <- anova(modelo_LG, modelo)
> anova_LG
Analysis of Variance Table

Model 1: Y ~ X123
Model 2: Y ~ X1 + X2 + X3
Res.Df   RSS Df Sum of Sq    F    Pr(>F)
1     498 366319
2     496 51427  2   314893 1518.5 < 2.2e-16 ***

```

$$F = \frac{[366319 - 51427] / 2}{MSE} = 1518.5$$

puede rechazar la hipótesis nula, así, se puede establecer que el efecto de la fuente es distinto al efecto de la Velocidad, o bien, el efecto es la primera covariable es distinto al efecto de las habilidades.

A un nivel de significancia del 5%, se

se cumple una o ambas