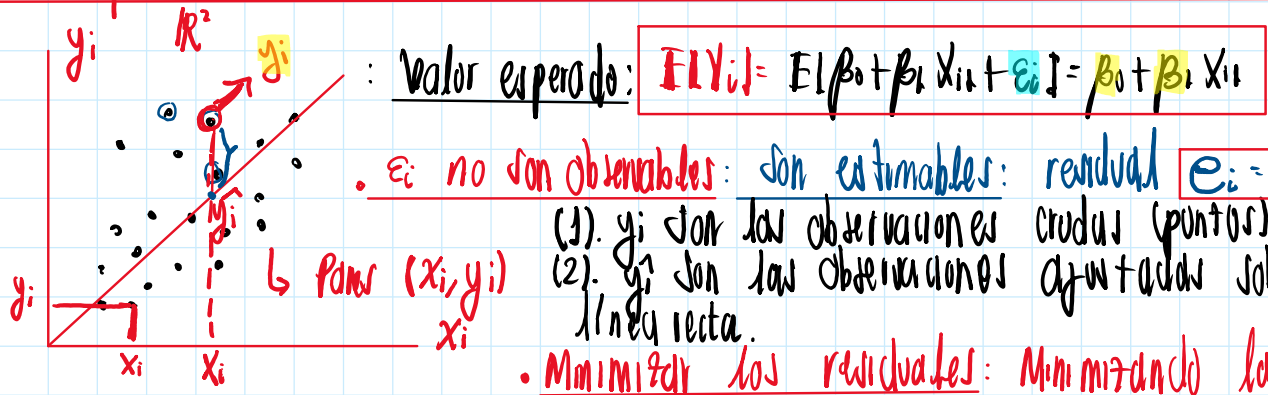


$Y_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_k X_{ik} + \epsilon_i$; $\epsilon_i \sim N(0, \sigma^2)$: $Y_i = \beta_0 + \beta_1 X_{i1} + \epsilon_i \rightarrow$ Volatilidad
(1). Independientes; (2). Identicamente distribuidos; (3). Media cero; (4). Varianza constante σ^2



$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_{i1}$: Determinístico: $\hat{\beta}_0, \hat{\beta}_1$: MLE, OLS

$Y_i \sim N(\beta_0 + \beta_1 X_{i1}, \sigma^2)$
 $\beta_0 \sim N(\beta_0, \frac{\sum_{i=1}^n X_{i1}^2 \sigma^2}{n S_{xx}})$
 $\beta_1 \sim N(\beta_1, \sigma^2 / S_{xx})$

$n = \#$ datos o covariar

Método estadístico
Método matemático

$\hat{\beta}_1 = \bar{y} - \hat{\beta}_0 \bar{x}$

$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}$

Promedio sobre las respuestas (Variable Ind).
Promedio sobre las observaciones (Variable Ind).
Promedio sobre X. (variables, variable independiente).

1. Realice un breve análisis descriptivo. ¿Un modelo de regresión lineal simple podría ser adecuado en este caso? ¿Por qué?

(1). Variables independientes altamente correlacionadas con la variable independiente podría ser útil.

Matriz de correlaciones En relación al problema

Correlación Pearson

FF	0.6	0.7	0.65	0.61	-0.1	-0.28	0.04	0.75	0.53	0.42	0.59	0.83	1
IF	0.79	0.71	0.62	0.61	-0.08	-0.28	0	0.7	0.47	0.46	0.57	1	0.83
TF	0.72	0.59	0.53	0.49	0.14	-0.26	0.12	0.7	0.54	0.43	1	0.57	0.59
MF	0.58	0.42	0.36	0.38	0.13	-0.1	0.02	0.43	0.47	1	0.43	0.46	0.42
LF	0.69	0.6	0.57	0.61	0.02	-0.2	-0.02	0.62	1	0.47	0.54	0.47	0.53
BF	0.87	0.84	0.82	0.77	-0.07	-0.4	0.05	1	0.62	0.43	0.7	0.7	0.75
FH	0.29	-0.05	-0.04	-0.09	0.18	0.19	1	0.05	-0.02	0.02	0.12	0	0.04
GS	-0.2	-0.55	-0.53	-0.53	0.43	1	0.19	-0.4	-0.2	-0.1	-0.26	-0.28	-0.28
TB	-0.06	-0.25	-0.28	-0.32	1	0.43	0.18	-0.07	0.02	0.13	0.14	-0.08	-0.1
JE	0.76	0.89	0.89	1	-0.32	-0.53	-0.09	0.77	0.61	0.38	0.49	0.61	0.61
GI	0.7	0.92	1	0.89	-0.28	-0.53	-0.04	0.82	0.57	0.36	0.53	0.62	0.65
PR	0.83	1	0.92	0.89	-0.25	-0.55	-0.05	0.84	0.6	0.42	0.59	0.71	0.7
OS	1	0.83	0.79	0.76	0.06	-0.2	0.29	0.87	0.69	0.58	0.72	0.79	0.8
OS	PR	GI	JE	TB	GS	FH	BF	LF	MF	TF	IF	FF	

Correlación

1.0
0.5
0.0
-0.5
-1.0

La variable independiente seleccionada va a ser GI.
Se va a ajustar con OS como respuesta

$Y_i = \beta_0 + \beta_1 X_{i1} + \epsilon_i$; $\epsilon_i \sim N(0, \sigma^2)$


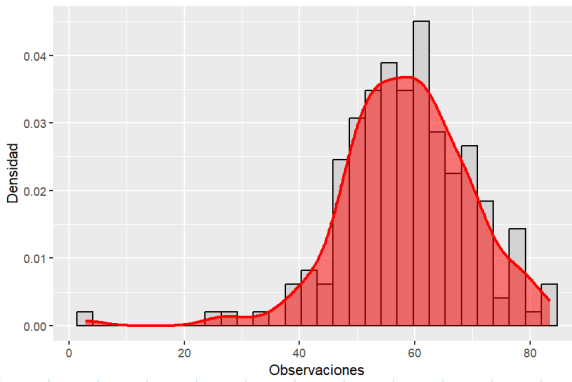
La correlación $-1 \leq P_{xy} \leq 1$
(1). Relación lineal perfecta

$OS_i = \beta_0 + \beta_1 GI_i + \epsilon_i$; $\epsilon_i \sim N(0, \sigma^2)$: $\hat{OS}_i = \hat{\beta}_0 + \hat{\beta}_1 GI_i$: $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_{i1}$

Histograma de densidad En relación a Overall Score

$Y_i \sim N(\beta_0 + \beta_1 X_{i1}, \sigma^2)$; $i = 1, \dots, 5$

Histograma de densidad
En relación a Overall Score



2. Escriba la ecuación del modelo de regresión lineal, considerando los supuestos asociados. Obtenga los valores calculados de los parámetros, \bar{y} , \hat{y} , $\hat{\epsilon}_i$ y analícelos.

$$OS_i = \beta_0 + \beta_1 GI_i + \epsilon_i; \epsilon_i \sim N(0, \sigma^2) \quad OS_i = \beta_0 + \beta_1 GI_i \quad Y_i = \beta_0 + \beta_1 X_i$$

$$lm: Y \sim X \quad e_i = y_i - \hat{y}_i$$

Diferencia entre las observaciones puntuales y la línea ajustada

```
Call:
lm(formula = OS ~ GI, data = data)

Residuals:
    Min       1Q   Median       3Q      Max
-38.987  -3.688   0.955   4.466  12.634

Coefficients:
(Intercept)  48.40987  1.17916  34.27  <2e-16 ***
GI           0.41041  0.02389  17.18  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.812 on 174 degrees of freedom
Multiple R-squared:  0.6291,    Adjusted R-squared:  0.6269
F-statistic: 295.1 on 1 and 174 DF, p-value: < 2.2e-16
```

$\alpha = 0.05$


$\hat{\beta}_0$
 $\hat{\beta}_1$

Recta de regresión ajustada: $\hat{Y}_i = 40.409 + 0.41041 X_i$

3. Determine si los parámetros del modelo β_0, β_1 son significativos, considerando $\alpha = 0.05$. Realice una interpretación en relación al problema. ¿Estos parámetros tienen sentido?

Problema de significancia: (1). Principio de parsimonia:

Visión económica: lo mejor posible pero de la forma más sencilla posible.




Revisar si el efecto de una variable es significativo sobre el modelo

Reparar el F1:

(1). Valor P: $P(|t_{n-2}| > |t_0|)$ En el caso de β_0 :

$$T_0: \frac{\hat{\beta}_0 - 0}{\sqrt{\text{Var}(\hat{\beta}_0)}} \sim t_{n-2}$$

Pruebas de hipótesis



$$\begin{cases} H_0: \beta_0 = 0 \\ H_1: \beta_0 \neq 0 \end{cases} \quad \text{Hipótesis de doble cola}$$

Se rechaza la hipótesis nula a un nivel de significancia α ($\alpha = 0.05$) del 5%, cuando el

~~XXXXXX~~

~~XXXXXX~~

• Se rechaza la hipótesis nula a un nivel de significancia α ($\alpha=0,05$) del 5%, cuando el $p < \alpha$

- Como se rechaza la hipótesis nula: los parámetros son significativos.
- El intercepto es significativo y la covariable GI es significativa


$$\begin{cases} H_0: \beta_j = 0 & j=0, \dots, k \\ H_1: \beta_j \neq 0 & j=0, 1 \end{cases}$$

j: Notación utilizada para los parámetros

• (2). Región de rechazo: $R_c = \{ |T| > t_{\alpha/2, n-2} \}$ $\alpha=0,1$ $\alpha=0,01$

• Una variable solo puede ser interpretable si es significativa: Por aumento unitario en la covariable GI, el cambio promedio en la respuesta es de 0,41091 Unidades

4. Calcule un intervalo de confianza -considerando $\alpha = 0.05$ - para ambos parámetros.
¿Puede concluir a partir de este resultado si los parámetros son significativos?



Intervalo de confianza:

$$\hat{\beta}_j \pm t_{\alpha/2, n-2} \cdot \sqrt{\text{var}(\hat{\beta}_j)}$$

```
> # Confint (para intervalos de confianza)
> confint(model)
                2.5 %      97.5 %
(Intercept) 38.0817785 42.7363582
GI           0.3632559  0.4575649
```

• Con una confianza del 95% se puede determinar que, por un aumento unitario en GI, el cambio promedio en OS, está comprendido entre 0,363 y 0,457 Unidades

• Si se cambia la confianza, cambia el intervalo (amplitud)

• $\alpha=0,1$: confianza 90%.

