

Tercer taller

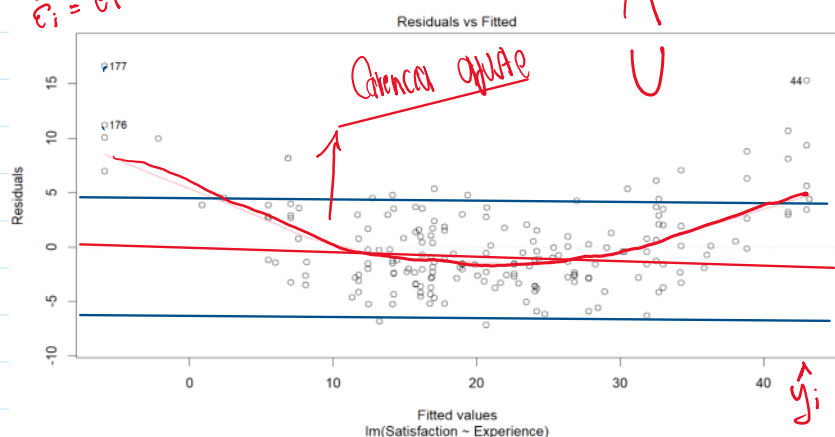
miércoles, 20 de noviembre de 2024 1:59 p. m.

Observación: Al interpretar los parámetros, es esencial fijarse en su signo. Por ejemplo, B1 negativo, con un valor de -8. Su interpretación práctica sería: Por un cambio unitario en X, Y disminuye en promedio 8 unidades. (No sería Y disminuye en promedio -8 unidades, ya que cambia el sentido de la interpretación.)

$$Y_i = \beta_0 + \beta_1 X_{i1} + \epsilon_i ; \epsilon_i \sim N(0, \sigma^2) : Y = \text{Satisfacción}; X = \text{Años de experiencia}$$

$$\beta_0 \rightarrow \beta_0 ; \epsilon_i \rightarrow \epsilon_i$$

$$\epsilon_i = \epsilon_i$$



El supuesto de medio cero siempre se cumple (Errors)

$$\sum_{i=1}^n \epsilon_i = 0$$

- A partir de la línea roja, se podría decir que el modelo está capturando un efecto no considerado por el modelo lineal.
- Hay patrón de carencia de ajuste. Y no decimos nada sobre la varianza.

- Existe una jerarquía: Es idóneo primero aplicar la prueba de carencia de ajuste y para luego considerar otras pruebas, errores y hacer inferencia sobre los parámetros (Prueba de significancia de la regresión y de los parámetros).

Probar criterio normalidad: (1). Gráfica


```
Call:
lm(formula = Satisfaction ~ Experience, data = datos)

Residuals:
    Min       1Q   Median       3Q      Max
-7.1882 -2.7119 -0.8805  2.5452 16.5908

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -8.0242     0.8563  -9.371  <2e-16 ***
Experience     5.4675     0.1516  36.066  <2e-16 ***
---
Signif. codes:
  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.998 on 188 degrees of freedom
Multiple R-squared:  0.8737, Adjusted R-squared:  0.8731
F-statistic: 1301 on 1 and 188 DF, p-value: < 2.2e-16
```

$$R^2 = \frac{SSR}{TSS}$$



(2). Analítica: Shapiro-wilk

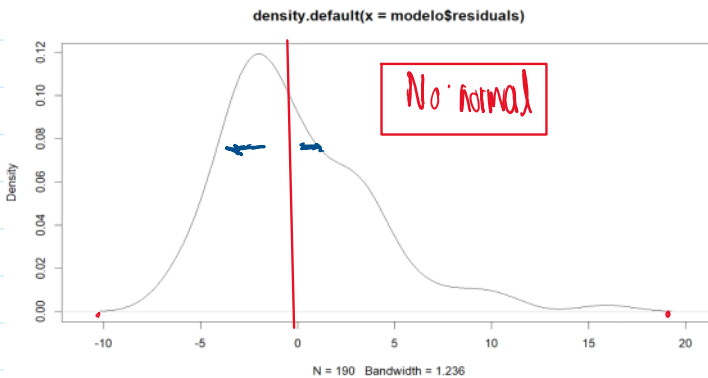
$$H_0: \epsilon_i \sim \text{normal} \quad i=1, \dots, n$$

$$H_1: \epsilon_i \not\sim \text{normal}$$

(2). Analítica: Shapiro-wilk $H_0: \varepsilon_i \sim \text{normal}$ $i=1, \dots, N$: $H_0: \varepsilon_i \sim N(0, \sigma^2)$
 $H_1: \varepsilon_i \neq \text{normal}$ $H_1: \varepsilon_i \neq N(0, \sigma^2)$
 $P_{val} < \alpha$ $\alpha = 0,05$ $\alpha = 0,1$ (esto no)

Shapiro-Wilk normality test
 data: modelo\$residuals
 W = 0.93966, p-value = 7.217e-08

- En función del valor P obtenido, existe evidencia suficiente para rechazar la H_0 . -> En términos del problema, los errores no tienen una distribución normal.
 $(P_{val} \approx 0,05 \quad \alpha = 0,05)$



- NO se cumplen los supuestos del modelo.

(Probar significancia de parámetros y regresión global)

$$Y_i = \beta_0 + \beta_1 X_{it} + \varepsilon_i$$

$T^2 = F$ Si y solo si $F \sim f_{1, \dots} \sim$ Una única variable regresaria

$$S.E(\hat{\beta}_j) \neq \sqrt{MSE}$$

$$H_0: \beta_j = 0 \quad j=0,1$$

$$H_1: \beta_j \neq 0$$

$$H_0: \beta_0 = 0$$

$$H_1: \beta_0 \neq 0$$

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

$$T = \frac{\hat{\beta}_j - 0}{S.E(\hat{\beta}_j)} \sim t_{n-2}$$

Bajo H_0 Cierta

$$P(|t_{n-2}| > |T_{calc}|) < \alpha$$

$$R_c: |T_{calc}| > t_{\alpha/2, n-2}$$

Coefficients:
 Estimate Std. Error t value Pr(>|t|)
 (Intercept) -8.0242 0.8563 -9.371 <2e-16 ***
 Experience 5.4675 0.1516 36.066 <2e-16 ***

 Signif. codes:
 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
 Residual standard error: 3.998 on 188 degrees of freedom
 Multiple R-squared: 0.8737, Adjusted R-squared: 0.8731
 F-statistic: 1301 on 1 and 188 DF, p-value: < 2.2e-16

$$P_{val}(\beta_0) < \alpha$$

$$P_{val}(\beta_1) < \alpha$$

- Hay evidencia suficiente para rechazar la hipótesis nula, en el caso de $j=0, 1$.

- Suponiendo que el modelo funciona, no hay carencia de ajuste, los supuestos sobre los errores, se podría concluir en términos prácticos.

$$X_{min} = 0 \geq 0$$

(No se puede interpretar)

Crear Intervalos de confianza:

2.5 % 97.5 %
 (Intercept) -9.713459 -6.335017
 Experience 5.168465 5.766559

- Por un cambio unitario en los años trabajados por los empleados del centro universitario, la satisfacción promedio cambia 5.46 unidades.
- Con una confianza de 95% se puede determinar que el efecto de la experiencia está comprendido entre 5,1 y 5,7 unidades.

$$T_{adj.} = 36,066 \quad F_{adj} = 1301$$

$$T^2 = 36,066^2 = F$$

$$F_{calc.} \quad P(|t_{n-2}| > |T_{calc}|) = P(f_{1,188} > F_{calc})$$

Analysis of Variance Table

5,1 y 5,7 unidades.

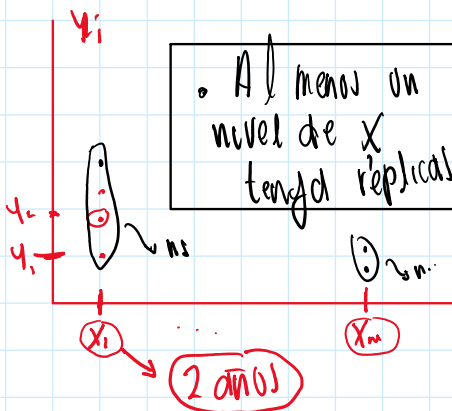


Analysis of Variance Table

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Experience	1	20790.7	20791	1300.8	< 2.2e-16 ***
Residuals	188	3004.8	16		

$$P(|t_{n-2}| > |t_{\alpha/2}|) = P(F_{1,188} > F_{\alpha/2})$$

$$F = \frac{SSR/1}{SSE/n-2} = \frac{MSR}{MSE} \sim F_{1,n-2}$$

Prueba de carencia de ajuste.



m = niveles

$$H_0: E(Y|X_i) = \beta_0 + \beta_1 X_i$$

$$H_1: E(Y|X_i) \neq \beta_0 + \beta_1 X_i$$

$$P_{val} < \alpha$$

$$F_{lof} \neq F_{sig} \quad F_{lof} = \frac{SSLOF/(m-2)}{SSPE/(n-m)} = \frac{MSLOF}{MSPE}$$

Bajo H0 cierta $\sim f_{m-2, n-m}$

$$SSPE = \sum_{i=1}^m \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_i)^2 \quad SSLOF = \sum_{i=1}^m n_i (\bar{y}_i - \hat{y}_i)^2$$

$$SSE = SSPE + SSLOF$$

$$(n-2) = m-2 + n-m$$

Análisis de varianza que incorpora la prueba de falta de ajuste en el modelo de RLS

Fuente de Variación	Suma de Cuadrados	Grados de Libertad	Cuadrado Medio	F Calculado
Regresión	SSR	1	$MSR = \frac{SSR}{1} = SSR$	$F_0 = \frac{MSR}{MSE}$
Error	SSE	n - 2	$MSE = \frac{SSE}{n-2}$	
Falta de Ajuste	SSLOF	m - 2	$MSLOF = \frac{SSLOF}{m-2}$	$F_0 = \frac{MSLOF}{MSPE}$
Error Puro	SSPE	n - m	$MSPE = \frac{SSPE}{n-m}$	
Total	SST	n - 1		

	Sum Sq	Df	Mean Sq	F value	Pr(>F)
Regression	20790.7	1	20790.7	1300.7898	< 2.2e-16 ***
Residuals	3004.8	188	16.0		
Lack of fit	2130.9	98	21.7	2.2392	6.69e-05 ***
Pure error	873.9	90	9.7		
Total	23795.5	189			

20 niveles con 3 réplicas

SSLOF, SSPE, MSLOF, MSPE, F_lof cal., P_val < alpha


Hay carencia de ajuste

- Generalmente, el problema de normalidad, está asociado a una heterocedasticidad.

Varianza no constante

- El problema de carencia de ajuste, podría solucionarse con una transformación.

$$Y_i = \beta_0 + \beta_1 X_{ii} + \epsilon_i \quad \epsilon_i \sim N(0, \sigma^2)$$



Exponential multiplicative:

$$Y_i = \beta_0 e^{\beta_1 X_i} \cdot \epsilon_i$$

$$\epsilon_i \sim \lognormal(\mu=0, \sigma)$$

Linearizar

$$Y_i^* = \ln(Y_i)$$

$$\ln(Y_i) = \ln(\beta_0 e^{\beta_1 X_i} \cdot \epsilon_i)$$



$$Y_i^* = \ln(\beta_0) + \beta_1 X_i + \ln(\epsilon_i)$$

Verificar supuestos modelo!

$$Y_i^* = \beta_0^* + \beta_1 X_{i1} + \epsilon_i^* ; \epsilon_i^* \sim N(0, \sigma^2)$$

$\sim \log(Y_i)$

Coefficients:				
	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.357843	0.051531	26.35	<2e-16 ***
Experience	0.288230	0.009123	31.59	<2e-16 ***




Shapiro-Wilk normality test

data: modelo2\$residuals

W = 0.89831, p-value = 4.504e-10

- En general, se busca no rechazar la prueba de normalidad.
- En general, se busca no rechazar la prueba de carencia de ajuste.



$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \epsilon_i$$

Prueba t

Significancia regresión: F

$$H_0: \beta_1 = \beta_2 = 0$$

$$Y_i = \beta_0 + \beta_1 X_{i1} + \epsilon_i$$

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$
$$H_0: \beta_1 = 0$$